

Assignment4

2024480022 홍정민

Problem1: α, β -Crown 디렉토리 탐색

1. 지원 모델의 아키텍처와 포맷

α, β -Crown은 **PyTorch**와 **ONNX** 형식의 모델을 지원한다. PyTorch 형식이 권장되며, 모델 정의 파일 (`model_defs.py`)에 모델 클래스를 등록하거나 커스텀 로더를 사용할 수 있다. ONNX 모델은 `model: onnx_path`를 통해 직접 경로를 지정한다.

지원되는 아키텍처는 다양하다. **이미지 분류**: ResNet (4-21 layers), CNN 기반 모델 (CIFAR-10/100, MNIST, TinyImageNet). **고급 모델**: Vision Transformers, Sigmoid/Tanh/GeLU 등 다양한 활성화 함수. **제어·의사결정**: ACAS Xu (항공기 충돌 회피), RL 모델 (CartPole, Lunar Lander), Lyapunov 안정 제어기. **특화 응용**: 신경망 기반 데이터베이스 인덱스, 쿼리 기수 예측, ML4ACOPF 등.

2. YAML 기반 검증 구성

α, β -Crown은 `python abcrown.py --config XXX.yaml` 명령으로 실행되며, YAML 파일에서 모든 설정을 정의한다.:

- Model: 모델 이름, 경로, 입력 형태
- Data: MNIST, CIFAR, TinyImageNet 등 내장 데이터셋 또는 커스텀 로더
- Specification: 입력 명시 (Lp norm, 원소별 경계, VNNLIB 파일), 출력 명시 (강건성, 선형 제약)
- Solver parameters: Branching 전략, Timeout, 메모리 옵션

알고리즘 선택: CNN/ResNet+ReLU는 Beta-CROWN with ReLU branching, 고차원 입력+비ReLU는 GenBaB, 저차원 제어 문제는 input space branching, 작은 모델은 MIP solver를 선택한다.

3. Marabou와의 주요 차이점

항목	Marabou	α,β -Crown
기술	SMT 기반	경계 전파 + Branch-and-Bound
설정 형식	표준화된 VNNLIB	유연한 YAML
모델 입력	ONNX만 지원	ONNX, PyTorch 모두
성능	느린 검증	빠른 검증
확장성	작은-중간 모델	더 큰 모델 (20+층)
활성화 함수	ReLU 중심	ReLU, Sigmoid, Tanh, GeLU 등
응용 범위	이미지 분류 중심	이미지, 제어, RL 등 광범위

Problem2: α,β -Crown 검증 실험

1. 모델 및 설정

모델: 2개의 컨볼루션 레이어와 1개의 fully-connected 레이어로 구성된 간단한 CNN 모델을 사용했다. 입력은 28×28 MNIST 이미지이고, 10개 클래스로 분류한다.

Conv2d(1→16)→ReLU→Conv2d(16→32)→ReLU→FC(1568→10) 구조이다.

데이터셋: MNIST 테스트 세트에서 첫 5개 이미지를 검증 대상으로 선택했다. 검증은 L_∞ 노름 기반 강건성으로, 픽셀 값의 최대 5% perturbation ($\epsilon=0.05$) 범위 내에서 분류 결과가 불변인지 확인한다. 각 인스턴스의 timeout은 60초로 설정했다.

2. 검증 결과

항목	값	항목	값
검증됨 (Safe)	3개	Falsified	0개
Timeout	2개	검증 정확도	60%

검증된 안전 인스턴스: 인덱스 0, 1, 3 (3개), Timeout 인스턴스: 인덱스 2, 4 (2개)

3. 성능 분석

시간 비용: 검증된 안전 케이스 3개의 평균 검증 시간은 1.04초로 매우 빠르다. 반면 전체 5개 인스턴스의 평균 시간은 25.13초로, 2개의 timeout 케이스가 각각 최대 61.44초까지 소요되면서 전체 평균을 크게 상향시킨다. 이는 일부 입력 영역에서 경계 전파가 충분한 bounding box reduction를 이루지 못해 과도한 branching이

발생했음을 보여준다.

검증 어려움: Timeout 케이스(인덱스 2, 4)는 60초 내에 완벽한 검증을 완료하지 못했다. 이러한 케이스들은 더 복잡한 강건성 속성을 가지거나 경계 전파 알고리즘이 덜 효과적인 입력 영역에 해당할 수 있다.

4. 결론

SimpleCNN의 MNIST 강건성 검증 결과는 대부분의 케이스에서 빠른 검증을 달성했다. 3개 인스턴스가 $\epsilon=0.05$ 범위 내에서 분류 불변성을 보였으며, 평가된 5개 샘플 중 60%가 검증되었다. Timeout이 발생한 2개 케이스를 추가 분석하면 더 강건한 모델 또는 보다 효율적인 검증 설정을 도출할 수 있을 것으로 예상된다.